DressMe

Architecture des agents IA

Dossier de validation technique

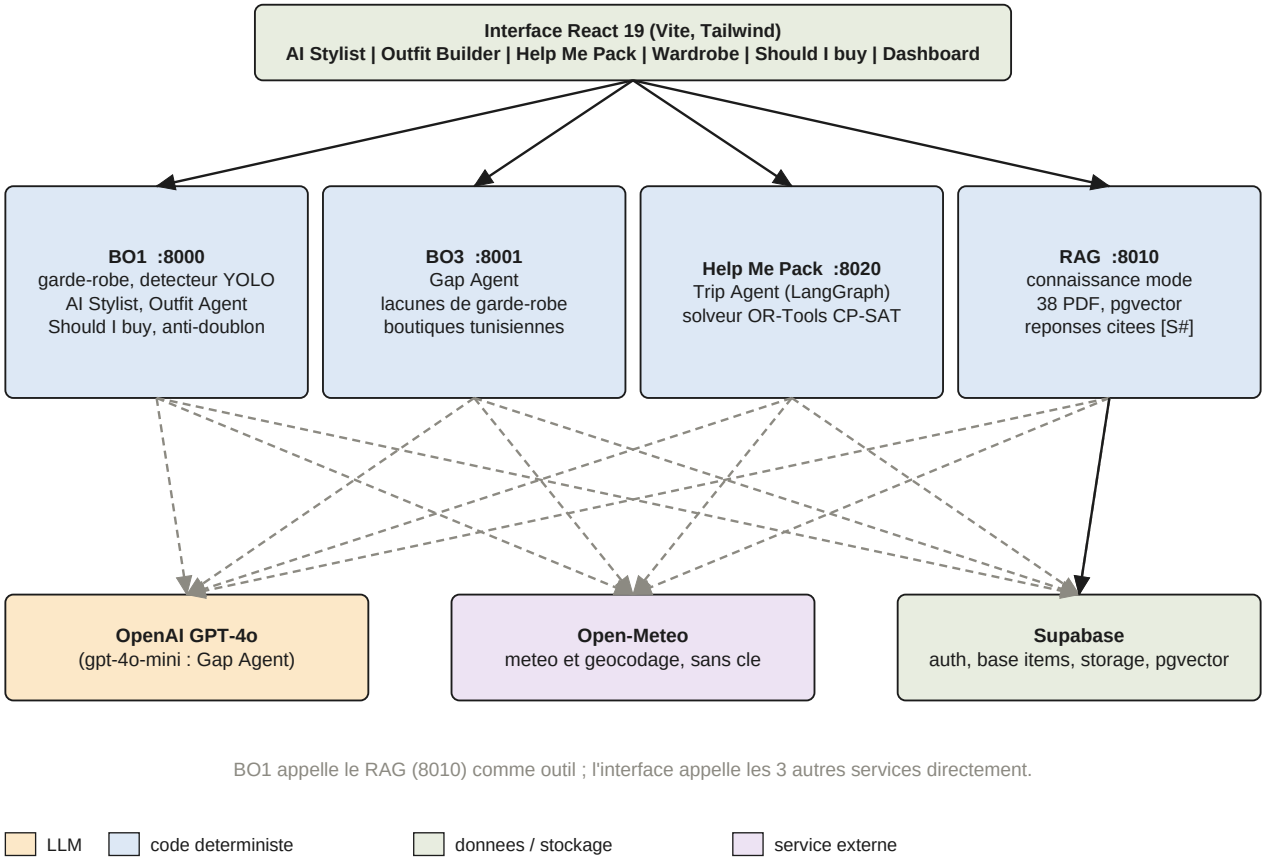
6 agents, 3 pipelines LLM, 1 RAG, 4 services, 11 ecrans, protocole A2A

Graphes, prompts, outils, integration, garde-fous et limites

Projet de fin d'etudes - application DressMe (React, FastAPI, LangGraph, OpenAI, Supabase)

1. Vue d'ensemble

DressMe est une application React 19 qui parle a **quatre services FastAPI** (BO1, BO3, Help Me Pack, RAG). Supabase fournit l'authentification, la base de donnees (garde-robe) et le stockage des images. OpenAI fournit le LLM, Open-Meteo la meteo reelle.



BO1 appelle le RAG (8010) comme outil ; l'interface appelle les 3 autres services directement.

Figure 1 : architecture globale, services et dependances externes.

Principe commun a tous les agents : le LLM decide et redige, le code deterministe verifie et calcule. Aucun agent ne peut citer une piece absente de la garde-robe, inventer la meteo ou inventer une source.

Ports et lancement

Service	Port	Role	Lancement
BO1 (backend/app)	8000	garde-robe, detecteur, AI Stylist, Outfit Agent, Should I buy, avatar	start_bo1.ps1
BO3 (DressMe UI Blueprint/backend)	8001	Gap Agent, produits de boutiques tunisiennes	start_bo3.ps1
Help Me Pack (backend/main.py)	8020	Trip Agent et solveur CP-SAT	start_packing.ps1
RAG (rag_backend)	8010	connaissance de mode citee	start_rag.ps1
Interface (Vite)	8443	application React (https de developpement)	pnpm dev

2. Integration de toutes les fonctionnalites

Chaque page de l'interface appelle une route ; la route appelle soit un **agent** (le LLM choisit des outils ou suit un graphe), soit un **moteur** (detecteur, moteur d'achat, comparaison locale). Le schema relie les 11 ecrans aux 6 agents et aux moteurs.

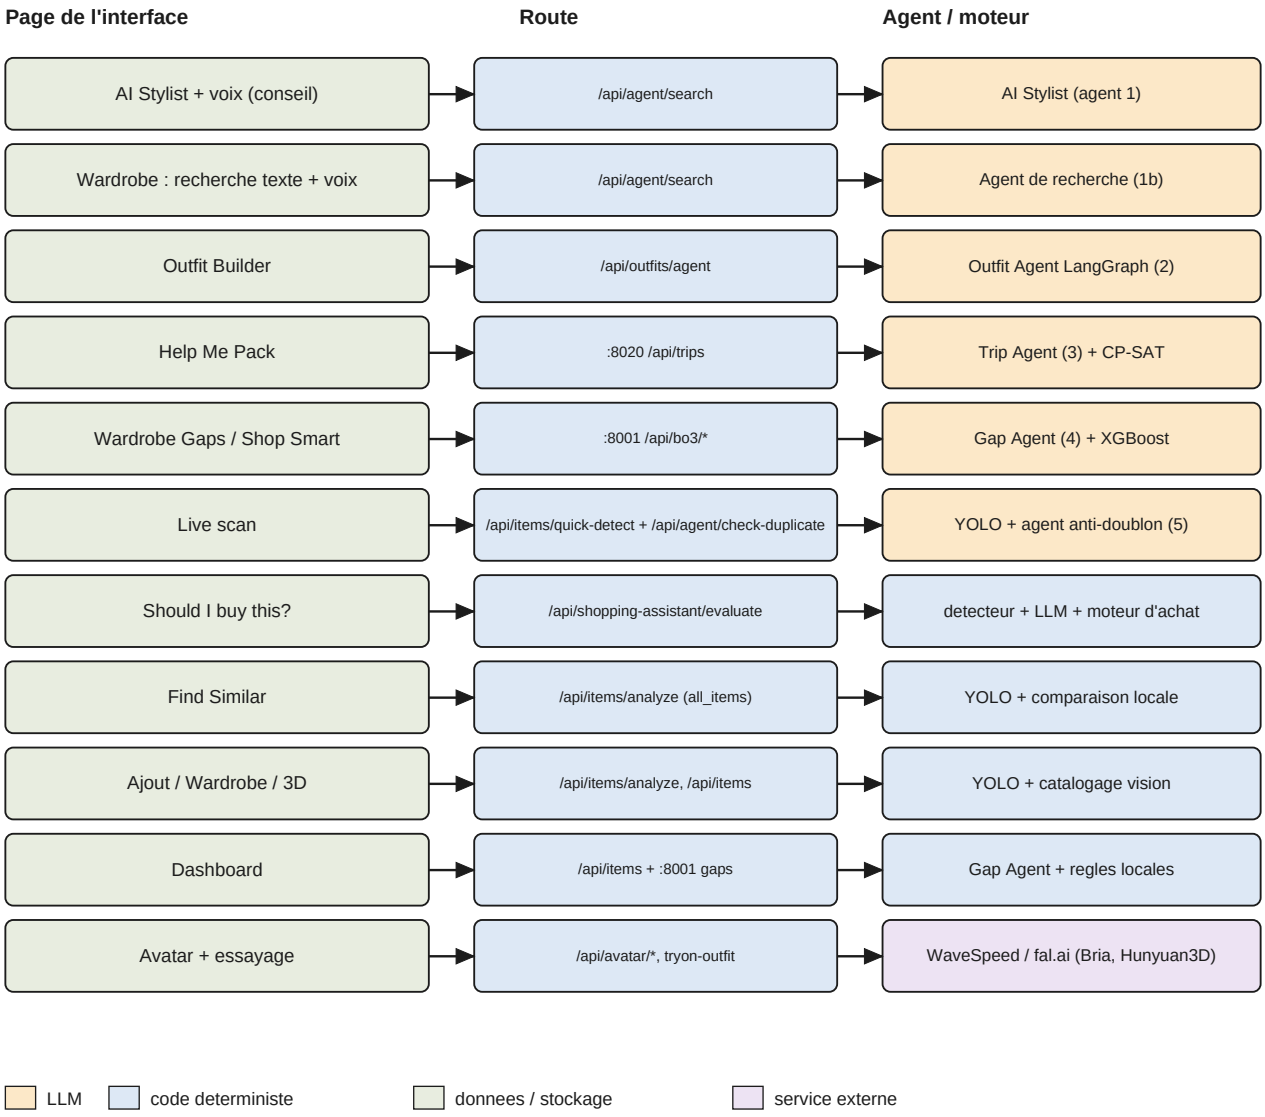


Figure 2 : de chaque page a l'agent ou au moteur qui la sert.

2.1 Recherche vocale



Transcription faite par le navigateur (Chrome et Edge utilisent leur service en ligne) : seul le texte arrive a nos serveurs.

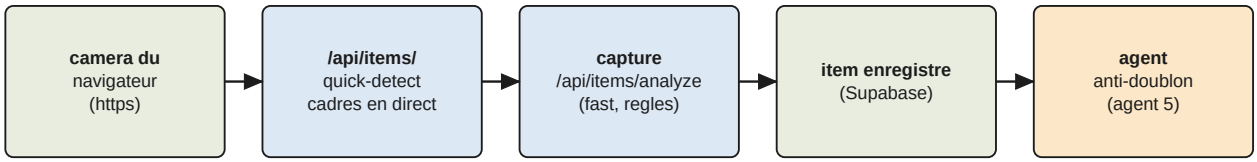
Voix ou texte : meme chemin. Le LLM choisit les filtres, le code filtre la garde-robe, la page affiche le resultat.

Figure 3 : recherche intelligente par la voix ou par le texte (agent 1b).

- **C'est bien un agent.** Le texte (ecrit ou dicte) est envoye au LLM, qui choisit lui-meme les parametres de recherche (categorie, couleur, saison, occasion, style, chaleur, texte libre), appelle l'outil `search_wardrobe`, **regarde le resultat** et recommence avec d'autres filtres si c'est vide ou trop large, puis redige sa reponse.

- Voix : hook `useSpeech` (Web Speech API du navigateur, transcription en direct) ; a la fin de la phrase le texte part comme une question ecrite.
- Page Wardrobe : la grille est filtree sur les pieces trouvees et les **filtres choisis par le LLM** s'affichent en pastilles ("jacket, warmth 4+"). Navigateur sans l'API vocale : le bouton micro est masque.
- **Meme code, deux usages** : la fonction `agent.chat` sert la recherche de la page Wardrobe (agent 1b : reponse courte + filtres + pieces) et la page AI Stylist (agent 1 : conseil complet avec meteo, tenue, raisons et sources). Le prompt distingue les deux : une simple recherche recoit une phrase, sans conseil ni sections.

2.2 Live scan



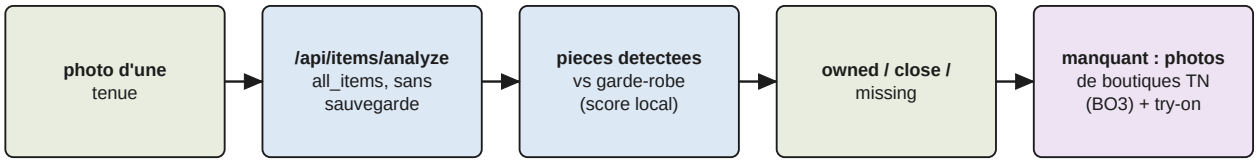
Pendant la camera : YOLO dessine les cadres et signale une photo floue ou un vetement coupe (module quality).

Apres chaque capture, l'agent decide avec search_wardrobe s'il s'agit du meme vetement scanne deux fois.

Figure 4 : scan en direct avec controle qualite et anti-doublon.

- La camera exige une origine securisee (https ou localhost) : le serveur de dev peut tourner en https avec un certificat local.
- `/api/items/quick-detect` renvoie les cadres, la couleur principale et un eventuel probleme (flou, coupe, trop petit).
- La capture passe par `/api/items/analyze?fast=true` (classification par regles, quelques centaines de ms), puis l'agent anti-doublon decide s'il faut avertir.

2.3 Find Similar



Aucun LLM : detecteur YOLO + comparaison par categorie, couleur, matiere et style cote interface.

Une piece manquante renvoie vers BO3 (/api/bo3/plan/photos) et vers l'essayage virtuel sur l'avatar.

Figure 5 : de la photo d'une tenue aux pieces manquantes.

- Une photo de tenue est decoupee en pieces par le detecteur ; chaque piece est comparee a la garde-robe (meme categorie, couleur, matiere, style) et classee **You own it**, **Close match** ou **Missing**.
- Pour une piece manquante, BO3 renvoie des photos de boutiques tunisiennes et l'utilisateur peut l'essayer sur son avatar avant d'acheter.
- Difference avec Should I buy : Find Similar part d'une tenue vue ailleurs ; Should I buy part d'un seul article et rend un verdict.

2.4 Dashboard

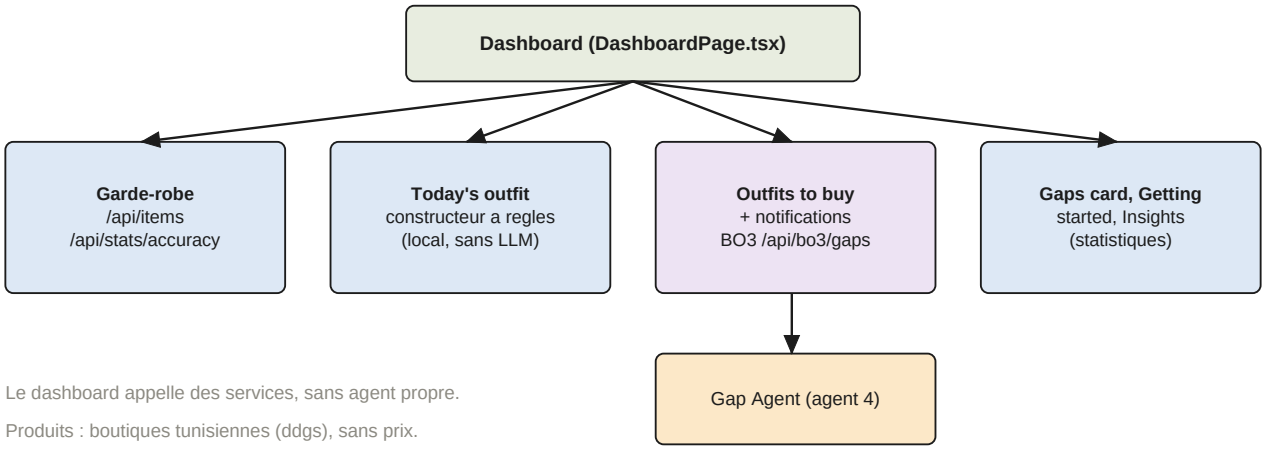


Figure 6 : composition du tableau de bord.

- **Outfits to buy** et les notifications viennent du Gap Agent (BO3) ; le panneau memorise l'objectif choisi pour prevenir quand des lacunes changent.
- **Today's outfit** utilise le constructeur a regles local (une tenue pour la saison courante) ; le Outfit Builder Agent est sur sa propre page.
- Les statistiques (nombre de pieces, repartition, precision du catalogage) viennent de `/api/items` et `/api/stats/accuracy`.

2.5 Essayage virtuel et avatar

- Avatar : photo en pied, puis modele 3D (Hunyuan3D v3) ; fournisseur configurable (WaveSpeed par defaut ou fal.ai, variable AVATAR_PROVIDER).
- Essayage d'une tenue, d'un vetement de boutique ou d'une tenue de l'Outfit Builder : `/api/avatar/tryon-outfit` et `tryon-garment` (Bria virtual try-on), execute en tache d'arriere-plan avec suivi d'etat.

2.6 Services partages par les agents

Service	Utilise par	Role
Supabase (auth, items, storage)	tous	jeton verifie sur chaque route, garde-robe de l'utilisateur, photos et cutouts
OpenAI GPT-4o	AI Stylist, Outfit Agent, Trip Agent, anti-doublon, catalogage, Should I buy	raisonnement, redaction, vision
Open-Meteo	AI Stylist, Outfit Agent, Trip Agent	geocodage + prevision 16 jours, cache 30 min
RAG (8010)	AI Stylist, Outfit Agent	conseils de livres de mode avec sources [S#]
YOLO dressme_best.pt	Wardrobe, Live scan, Find Similar, Should I buy	detection et segmentation des vetements
OR-Tools CP-SAT	Trip Agent	choix optimal de la valise
XGBoost	Gap Agent, Should I buy	classement des lacunes, decision d'achat
WaveSpeed / fal.ai	Avatar, essayage	generation 3D et try-on

3. Combien d'agents ?

6 agents (5 moteurs distincts, dont un partage entre 1 et 1b) sont appeles depuis l'interface. **3 pipelines** utilisent un LLM sans etre des agents (le LLM ne choisit pas ses outils). Une **pile separee de l'equipe** (Stylist BO4 et orchestrateur) existe aussi, non branchee a l'interface React.

#	Agent	Fonctionnalite	Technique	Fichier
1	AI Stylist	page AI Stylist (texte et voix)	boucle d'appel d'outils GPT-4o, 3 outils	backend/app/agent.py
1b	Agent de recherche intelligente	recherche texte ou voix de la page Wardrobe	meme boucle, le LLM choisit les filtres de search_wardrobe	backend/app/agent.py (chat)
2	Outfit Builder Agent	page Outfit Builder	graphe LangGraph, 5 noeuds	backend/app/outfit_agent.py
3	Trip Agent	Help Me Pack	GPT-4o, 10 outils, LangGraph (2 graphes), CP-SAT	packing_backend/trip_agent/
4	Gap Agent (BO3)	Wardrobe Gaps, Shop Smart, Outfits to buy	5 outils, 6 etapes max, XGBoost	DressMe UI Blueprint/backend/agent/gap_agent.py
5	Agent anti-doublon	Live scan (camera)	1 outil (search_wardrobe)	backend/app/agent.py (check_duplicate)

Pipeline LLM	Role	Fichier
Catalogage vision	detecteur YOLO, puis GPT-4o vision (JSON strict) : categorie, couleur, matiere, saison, occasion	backend/app/enricher.py
Should I buy this?	detecteur + LLM, moteur d'achat (XGBoost + regles), puis LLM qui redige 3 sections	smart_purchasing/inference.py
Reponse RAG	recherche hybride, puis LLM qui repond uniquement avec les sources	rag_backend/rag/rag_service.py

Pile separee (non branchee a React)	Technique
Stylist BO4 (bo4/)	LangGraph a 9 noeuds, Ollama qwen2.5:3b, moteur de tenues heuristique (couleur 30, style 20, occasion 30, saison 20)
Orchestrateur (orchestrator/, port 8070)	LangGraph : route_intent (regles puis LLM local) vers stylist, garde-robe, achat, RAG ou clarification

LangGraph est utilise par l'Outfit Builder Agent, le Trip Agent, le Stylist BO4 et l'orchestrateur. L'AI Stylist, le Gap Agent et l'agent anti-doublon utilisent la boucle d'appel d'outils native d'OpenAI, ecrite a la main.

4. Outils de chaque agent

Un **outil** est une fonction que le LLM peut demander ; le code l'execute et renvoie le resultat au LLM. Le LLM ne touche jamais directement aux donnees.

4.1 AI Stylist et agent de recherche : 3 outils

Outil	Parametres	Retour	Garde-fou
search_wardrobe	category, category_group, color_name, season, occasion, style, pattern, min_warmth (1-5), text (choisis par le LLM, voix ou texte)	jusqu'a 20 pieces : id, nom, categorie, couleur, matiere, saisons, style, occasions, formalite, chaleur	valeurs d'enumeration imposees ; seuls les items de l'utilisateur
get_weather	days_ahead (0 a 15), city (optionnel)	ville, jour, condition, min/max en C et F, % de pluie, mm, vent, resume	ville inconnue : premiers mots, puis Tunis, annoncee ; sinon "non verifiee"
fashion_advice	question (anglais, un seul sujet)	answer + sources [{marker, title, page}]	None si RAG arrete ou sans citation : l'agent le dit

4.2 Outfit Builder Agent : 5 noeuds (pas d'appel d'outils)

Noeud	Entree	Sortie	Type
weather	ville, pays	forecast (ou None)	code, Open-Meteo
closet	items	closet : pieces par role avec 13 champs	code
knowledge	occasion, saison, forecast	advice[] + sources	RAG, 2 questions
compose	brief : occasion, meteo, conseils, tenues deja vues, placard	outfits[] {title, items[ids], weather_note, why[]}, missing[]	GPT-4o JSON, temp. 0,6
validate	outfits[] + placard	tenues valides ou liste d'erreurs (retour a compose une fois)	code

4.3 Trip Agent : 10 outils (valides par Pydantic)

Outil	Role	Ressource
get_trip_details	extrait, fusionne et valide les champs du voyage ; signale ceux qui manquent	GPT-4o JSON + regex de secours
get_weather	prevision jour par jour pour la destination et les dates (force_refresh, allow_network)	Open-Meteo, repli synthetique etiquete
get_wardrobe	charge la garde-robe (filtres category, style, limit) et la couverture des roles	CSV + compatibilite (pandas)
get_activity_requirements	traduit activites, meteo et formalite en exigences quotidiennes du solveur	regles deterministes
optimize_trip	choisit la valise : moins de pieces, plus combinables, poids minimal	OR-Tools CP-SAT
generate_checklist	cree la checklist (tout non emballe) depuis la capsule	modeles Pydantic
suggest_alternatives	diagnostique INFEASIBLE et propose des options sans relacher les contraintes	CP-SAT + analyse des roles
update_trip	modifie dates, destination, activites, tenue ou poids ; invalide l'etat obsolete ; re-optimise au choix	etat de l'agent
update_checklist	coche ou decoche une piece sans relancer le solveur	etat de l'agent
check_gaps	crochet optionnel vers le Gap Agent (peut repondre indisponible)	fonction injectee

4.4 Gap Agent BO3 : 5 outils

Outil	Parametres	Role
get_wardrobe	aucun	profil de style + resume de chaque piece possedee
compute_coverage	goal (enum des objectifs)	exigences couvertes ou manquantes ; les regles decident si une lacune existe
rank_gaps	goal	score chaque exigence manquante (deficit, frequence d'usage, saison, gain de tenues, preference, redondance FashionCLIP) puis classe avec XGBoost ; sauvegarde l'analyse
get_past_analyses	aucun	memoire a long terme : analyses precedentes de l'utilisateur
show_items	item_ids (8 max)	affiche les pieces citees comme cartes photo a cote de la reponse

Le Gap Agent a une vraie **memoire** (analyses passees) et un **apprentissage** : les retours de l'utilisateur sur les suggestions reentrainent le classeur (/api/bo3/retrain).

4.5 Agent anti-doublon : 1 outil

Outil	Parametres	Role
search_wardrobe	memes filtres que l'AI Stylist	cherche un quasi-doublon du vetement capture ; reponse finale JSON {duplicate, similar_item_id, note}

5. AI Stylist

Entree : `POST /api/agent/search` avec message, city, country, unit. La ville du profil est utilisee, sinon **Tunis, Tunisie**. **Modele :** GPT-4o, temperature 0,3, sortie JSON, 8 tours maximum.

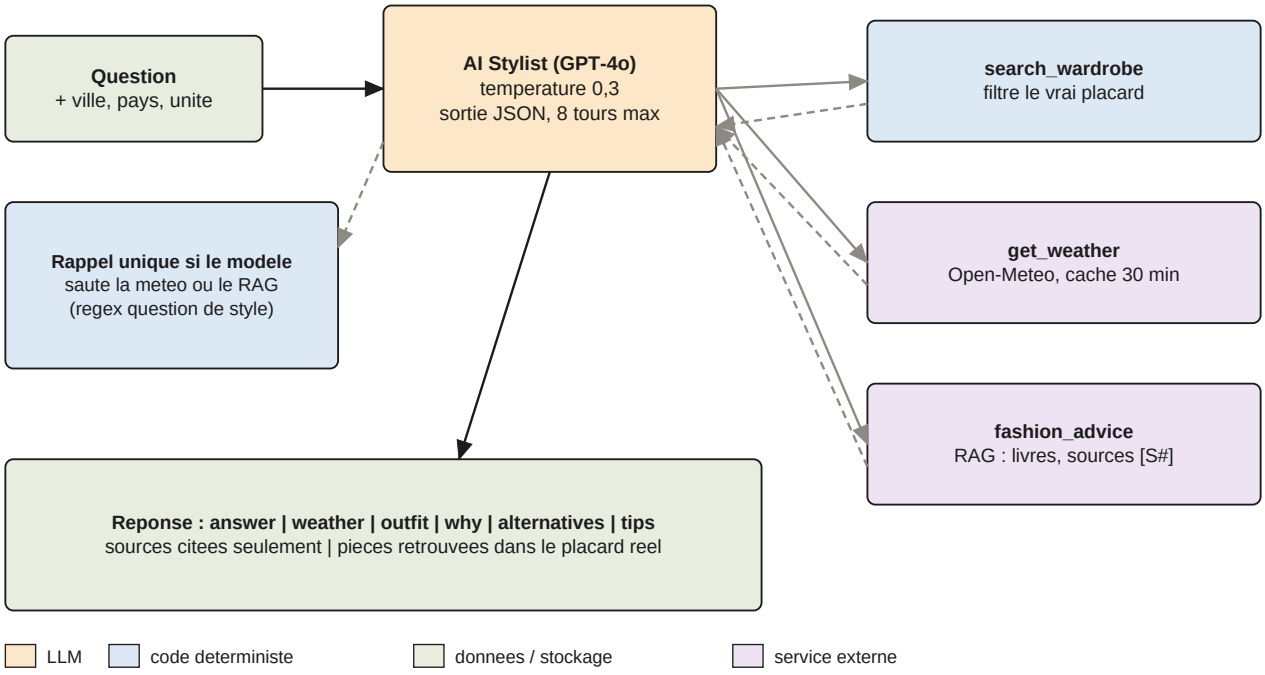


Figure 2 : boucle d'outils de l'AI Stylist.

Outils

Outil	Ce qu'il fait	Source
search_wardrobe	filtre la vraie garde-robe (categorie, couleur, saison, occasion, style, chaleur, texte)	table items (Supabase)
get_weather	prevision du jour voulu (aujourd'hui, demain, "vendredi"), en C ou F, 30 min de cache	Open-Meteo
fashion_advice	une question de style par sujet (jusqu'a 3), reponse avec [S#]	RAG (8010)

Prompt systeme (regles)

- Toujours appeler **search_wardrobe** avant de repondre ; ne parler que de pieces possedees ; si rien ne convient, le dire.
- **Meteo** : pour toute question "que porter / quelle tenue", appeler get_weather pour le jour voulu et citer les chiffres reels.
- **Livres** : pour toute question de style, appeler fashion_advice une fois par sujet (code vestimentaire, couleurs, tissus du climat).
- Ne jamais presenter un conseil de livre comme venant du placard ; ne jamais inventer de source.
- Position claire et convaincante : "My pick: ..." seulement pour une demande de conseil.

Format de reponse final (JSON, sans markdown ni emoji)

Cle	Contenu
answer	2 phrases : le choix puis la meilleure raison
weather	1 a 2 phrases : prevision chiffree et ce qu'elle impose
outfit	0 a 3 tenues, noms exacts des pieces reliees par " + "
why	4 a 6 raisons : meteo, occasion, couleurs, matieres, role des pieces ; chacune appuyee sur un fait reel et un [S#]
alternatives	0 a 3 lignes : ce qui a ete envisage et pourquoi ecarte
tips	2 a 3 conseils pratiques, avec [S#] quand ils viennent des livres

Garde-fous

- Rappel unique si le modele saute la meteo ou le RAG sur une question qui les demande (detection par expression reguliere FR/EN).
- Seules les sources reellement citees dans le texte sont renvoyees ; les pieces de la tenue sont retrouvees par leur nom dans le placard.
- Ville inconnue du service meteo : essai sur les premiers mots du nom, sinon meteo de Tunis annoncee comme telle.
- RAG ou meteo en panne : l'agent repond sans eux et le dit.

6. Outfit Builder Agent (LangGraph)

Route `POST /api/outfits/agent` (occasion, saison, ville, tenues deja montrees). Un graphe d'etat partage ou chaque noeud a un seul travail ; le LLM n'intervient que ou le jugement est necessaire.

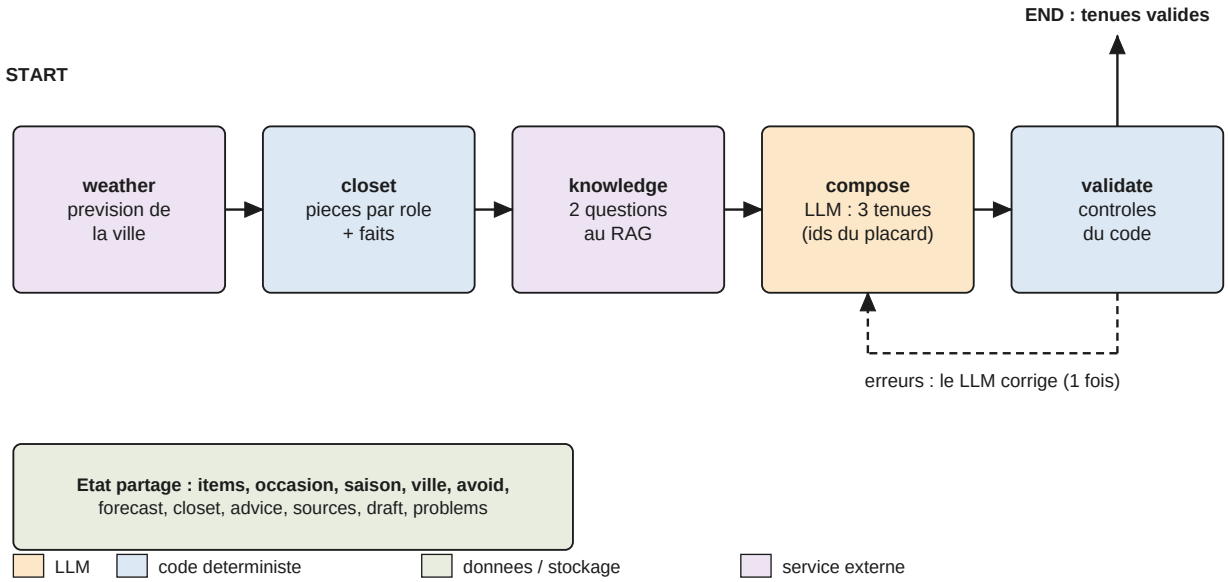


Figure 3 : graphe LangGraph de l'Outfit Builder.

Noeud	Role	LLM
weather	prevision reelle de la ville (Tunis par defaut)	non
closet	pieces classees par role : hauts, bas, robes, vestes, chaussures, avec couleur, matiere, saison, chaleur, formalite	non
knowledge	2 questions au RAG : code vestimentaire de l'occasion ; couleurs et tissus pour le climat du jour	RAG
compose	construit 3 tenues avec les identifiants du placard, donne un titre, une note meteo chiffree et 3 a 5 raisons	GPT-4o, JSON
validate	ids reels ; robe seule ou haut + bas ; chaussures ; pas deux pieces du meme role ; veste s'il fait froid ou pluvieux	non

Boucle de correction

Si une tenue est invalide, le LLM est renvoye **une seule fois** avec la liste exacte des erreurs ("Outfit 2: it has no shoes"). Seules les tenues valides sont retournees. Le bouton Shuffle envoie les tenues deja vues (`avoid`) pour en obtenir d'autres.

Interface et repli

- Bandeau meteo, titre de chaque look, phrase "Weather", liste "Why this outfit", bouton essayage virtuel, livres cites.
- Si l'agent est indisponible, l'ancien constructeur a regles (`outfitBuilder.ts`) prend le relais : la page affiche toujours quelque chose.
- Les pieces manquantes ("a rain jacket") ne sont signalees que si les conditions le justifient.

7. Trip Agent : Help Me Pack

Modele : GPT-4o, temperature 0, appel d'outils natif, 12 iterations maximum. Le LLM choisit l'outil suivant ; le code valide les arguments (Pydantic), impose les dependances et calcule la valise avec **OR-Tools CP-SAT**.

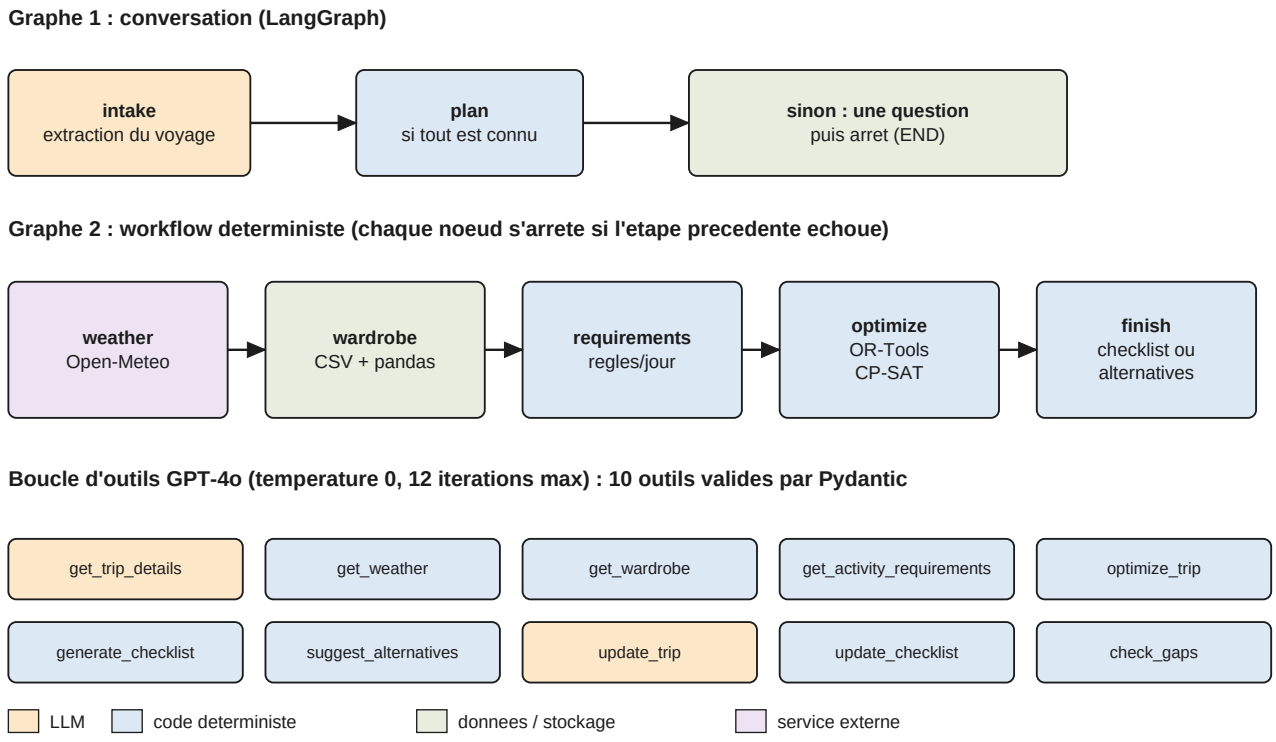


Figure 4 : deux graphes LangGraph et les 10 outils du Trip Agent.

Memoire

Type	Contenu	Duree
Travail	AgentState : voyage valide, meteo, placard, exigences, resultat du solveur, capsule, checklist, erreurs	une session
Conversation	16 derniers messages injectes dans le prompt	une session
Session	instance de l'agent par session_id, protegee par un verrou	jusqu'au redemarrage
Client	session_id dans le localStorage pour reprendre apres un rafraichissement	navigateur

Regles du prompt (10)

- Ne jamais inventer destination, dates, duree, activites, limite de bagage, meteo, pieces ni resultat du solveur.
- Voyage nouveau : get_trip_details d'abord ; s'il manque un champ, poser UNE question concise et s'arreter.
- Ordre : get_weather, get_wardrobe (une fois), get_activity_requirements, optimize_trip, puis generate_checklist.
- INFEASIBLE : suggest_alternatives ; ne jamais relacher silencieusement une contrainte dure.
- update_trip seulement pour modifier un voyage ; update_checklist pour cocher sans relancer le solveur.
- Une erreur d'outil se corrige ou s'explique, jamais un succes fabrique.

8. Gap Agent BO3 et boutiques tunisiennes

Modele : gpt-4o-mini par defaut, temperature 0,2, 6 etapes maximum. Il repond a "que manque-t-il dans ma garde-robe pour tel objectif ?" uniquement a partir des resultats d'outils.

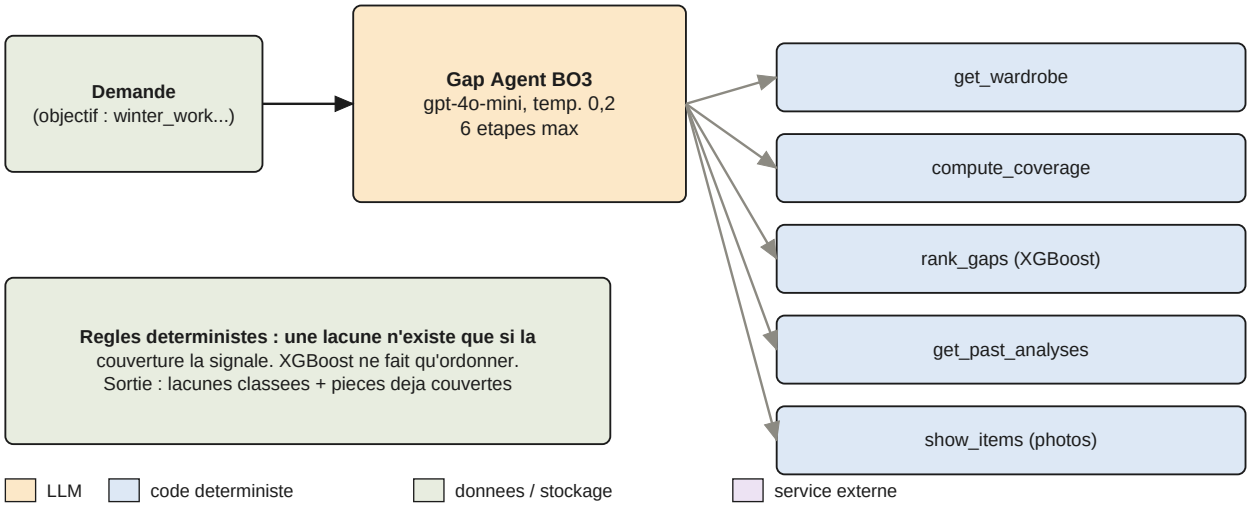


Figure 5 : Gap Agent et ses 5 outils.

- **Couverture** : regles deterministes par objectif et saison. Une lacune n'est reelle que si ces regles la signalent.
- **XGBoost** ordonne les lacunes ; son score n'est pas une probabilite, et il est entraine sur des donnees synthetiques tant qu'il n'y a pas de retours reels (le prompt le fait dire).
- **Departement** (femme, homme) : jamais de piece d'un autre departement ; jamais de genre devine.
- **Aval** : les lacunes alimentent "Outfits to buy" du tableau de bord, avec des produits de boutiques tunisiennes (recherche d'images ddgs) et l'essayage virtuel.
- Reponse dans la langue de l'utilisateur (anglais, francais, arabe tunisien).

Agent anti-doublon (Live scan)

Apres chaque capture camera, GPT-4o (temperature 0,1, 250 tokens) appelle `search_wardrobe` pour decider s'il s'agit du **meme** vetement scanne deux fois, et non d'"un autre t-shirt marine". Reponse JSON : duplicate, similar_item_id, note.

9. Pipelines assistes par LLM

9.1 Catalogage d'un vetement



Sans cle API ou en cas d'erreur : regles de secours (fallback_enrich)

Figure 6 : de la photo a la fiche vetement.

GPT-4o ne change la categorie du detecteur que si l'image le montre clairement ; la couleur est choisie dans la palette la plus proche de la mesure sur les pixels ; les scores de confiance doivent etre honnetes (bas si l'image est ambigue).

9.2 Should I buy this?

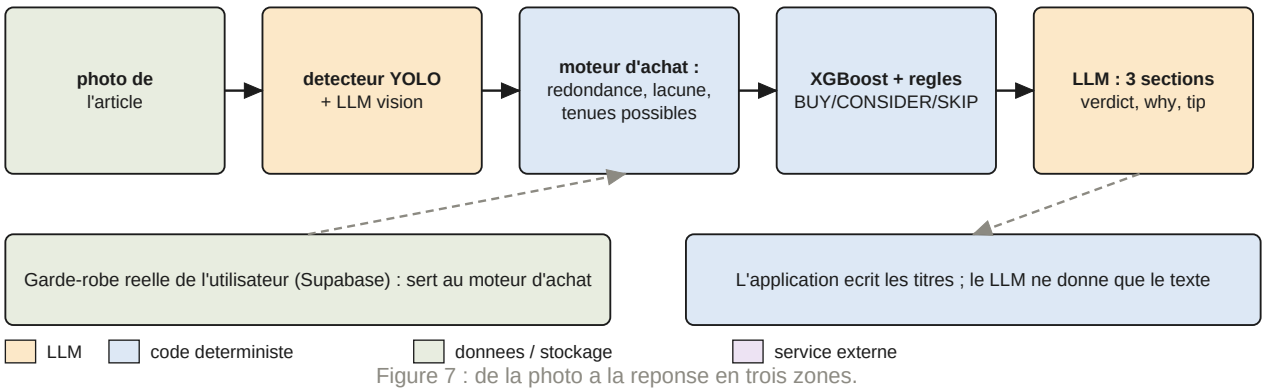


Figure 7 : de la photo a la reponse en trois zones.

- L'article est reconnu par le **meme** detecteur + LLM que le placard : pas de second moteur de vision.
- Le moteur d'achat calcule redondance, lacune comblee, tenues possibles avec les pieces possedees et prix par tenue.
- Le LLM (temperature 0,5) ne redige que trois sections : **verdict** ("Yes, buy it:", "Think twice:", "Skip it:" + raison), **why_it_works** (3 phrases avec un fait : nombre de tenues, nom d'une piece possedee, prix) et **final_advice**.
- Le prompt interdit le jargon (XGBoost, score, redondance), les emojis, le markdown et les symboles monetaires ; l'application ecrit les titres en gras.

10. Le RAG : connaissance de mode citee

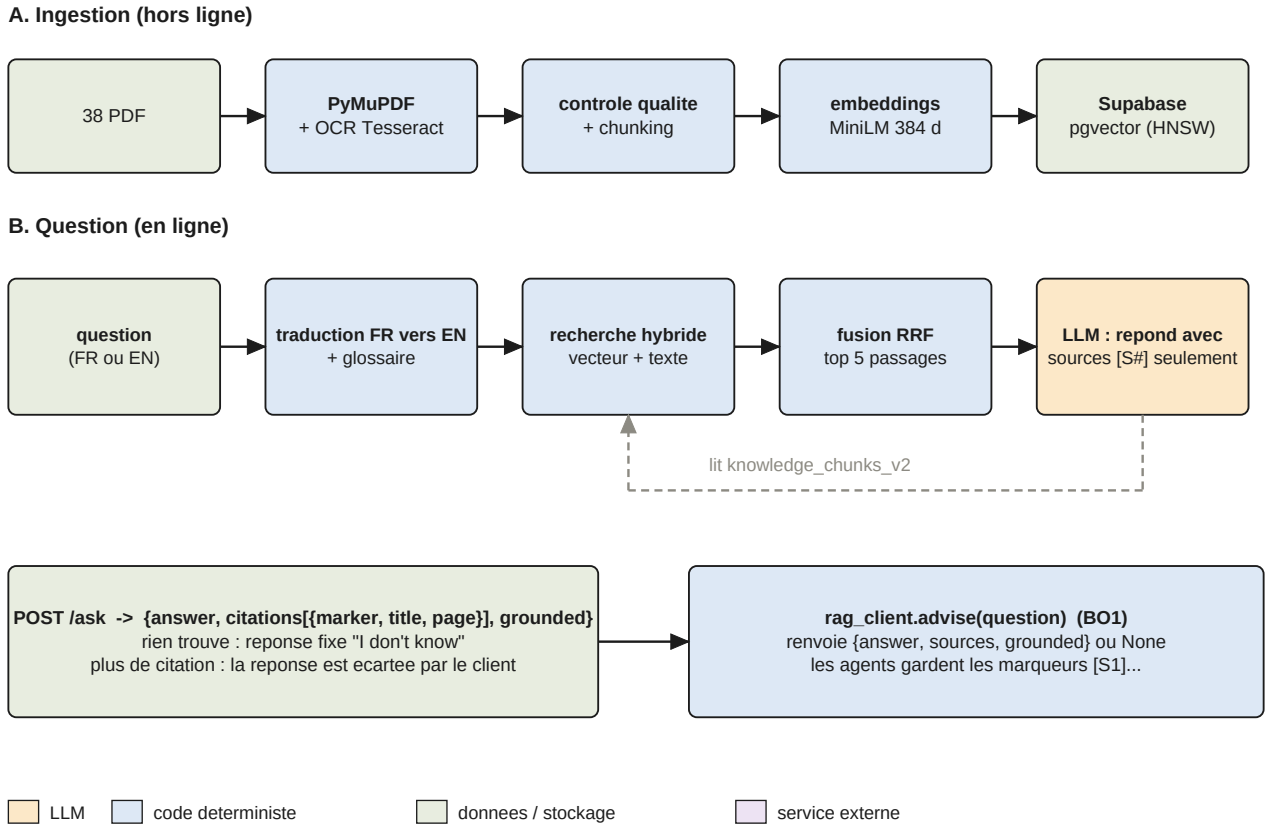


Figure 8 : ingestion et interrogation du RAG.

Element	Detail
Corpus	38 PDF (couleurs, tissus, codes vestimentaires, capsules, accessoires...), OCR Tesseract pour les livres scannes
Index	table knowledge_chunks_v2 (Supabase Postgres + pgvector, HNSW, cosinus), 384 dimensions, all-MiniLM-L6-v2
Recherche	hybride : vecteurs + recherche plein texte Postgres, fusion RRF, top 5 passages
Question	francais traduit en anglais (glossaire), anglais inchange
Generation	repond UNIQUEMENT avec les sources numerotees ; chaque puce finit par [S#] ; sinon la reponse fixe "I don't know"
API	POST /ask, /ask/stream (SSE), cle d'API, limitation de debit, historique de conversation

Integration dans les agents

- `rag_client.advise(question)` appelle /ask et renvoie {answer, sources:[{marker, title, page}], grounded}, ou None si le service est arrete, vide ou sans citation.
- L'AI Stylist l'expose comme outil **fashion_advice** ; l'Outfit Agent l'appelle dans le noeud **knowledge**.
- Les agents gardent les marqueurs [S#] dans leurs phrases ; l'interface les affiche en badges (survol : livre et page) et liste les livres sous "From fashion books".
- Le RAG ne connait pas le placard : c'est l'agent qui fait le lien entre la regle du livre et les pieces reelles.

11. Qui utilise quoi

Fonctionnalite	Agent / pipeline	Meteo	RAG	Placard	Solveur / ML
AI Stylist	AI Stylist	oui	oui	oui	non
Outfit Builder	Outfit Builder Agent	oui	oui	oui	non
Help Me Pack	Trip Agent	oui	hook prevu	oui	OR-Tools CP-SAT
Wardrobe Gaps, Shop Smart, Outfits to buy	Gap Agent	non	non	oui	regles + XGBoost
Should I buy this?	pipeline detecteur + LLM + moteur d'achat	non	non	oui	XGBoost
Live scan	detecteur + agent anti-doublon	non	non	oui	YOLO
Ajout d'un vetement	detecteur + catalogage vision	non	non	non	YOLO

Prompts : parametres LLM par composant

Composant	Modele	Temperature	Sortie	Limite
AI Stylist	GPT-4o	0,3	JSON	8 tours, 1800 tokens
Outfit Agent (compose)	GPT-4o	0,6	JSON	2 passes max, 2200 tokens
Trip Agent	GPT-4o	0	outils + JSON	12 iterations
Gap Agent	gpt-4o-mini	0,2	Markdown	6 etapes
Anti-doublon	GPT-4o	0,1	JSON	250 tokens
Should I buy (rédaction)	GPT-4o	0,5	JSON 3 sections	-
Catalogage vision	GPT-4o	-	schema JSON strict	-

Cycle d'une requete (exemple : "Que mettre demain pour un diner ?")

- 1. React envoie message + ville + unite du profil a BO1.
- 2. L'AI Stylist appelle get_weather (demain), search_wardrobe (saison, occasion) puis fashion_advice (code vestimentaire, couleurs).
- 3. GPT-4o redige le JSON : choix, meteo chiffree, tenue, 4 a 6 raisons, alternatives, conseils.
- 4. BO1 filtre les sources citees, retrouve les pieces dans le placard et renvoie la reponse + la prevision.
- 5. React affiche les zones Weather, Outfit idea (photos), Why I chose this, What else I considered, Tips, From fashion books.

12. Garde-fous, securite et tests

Theme	Mesure
Ancrage	identifiants du placard seulement ; outils en lecture ; sources numerotees ; meteo reelle ; "never invent" dans chaque prompt
Validation par du code	Outfit Agent (regles de composition), Trip Agent (Pydantic + solveur), AI Stylist (filtrage des sources citees)
Degradation douce	RAG, meteo ou LLM indisponibles : reponse partielle ou repli par regles, jamais une page cassee
Securite	jeton Supabase verifie sur chaque route ; chaque utilisateur ne voit que son placard ; cles API cote serveur uniquement ; limitation de debit du RAG
Honnetete	le prompt du Gap Agent dit que le classeur est entraine sur des donnees synthetiques ; le RAG repond "I don't know" plutot que d'inventer
Tests	85 tests backend (faux LLM, faux RAG, faux service meteo), 30 tests frontend, tests du moteur d'achat et du Trip Agent ; essais reels de bout en bout avec GPT-4o, le RAG et Open-Meteo

Limites assumees

- Le RAG ne connait pas le placard de l'utilisateur ; il ne contient que des livres de mode.
- Le classeur XGBoost du Gap Agent est entraine sur des donnees synthetiques jusqu'a l'arrivee de retours reels.
- L'AI Stylist n'a pas de memoire entre deux messages ; la memoire du Trip Agent est en memoire serveur (perdue au redemarrage).
- Le Stylist BO4 et l'orchestrateur LangGraph ne sont pas encore relies a l'interface React.
- La meteo est celle d'un jour (jusqu'a 15 jours) pour une seule ville.
- Pistes : orchestrateur client A2A, memoire de preferences par utilisateur, journal de ce qui est porte, migration de l'AI Stylist vers LangGraph.
- A2A : implementation legere du protocole (JSON-RPC, cartes d'agent) ; streaming et notifications push non implementes.

13. Communication entre agents : protocole A2A

Chaque agent expose une **carte d'agent** (qui il est, ses competences, comment s'authentifier) et un point d'entree **JSON-RPC** (protocole Agent2Agent, version 0.3). N'importe quel agent ou l'orchestrateur peut donc le decouvrir et lui confier une tache par HTTP, sans connaitre ses routes internes. Le code commun est dans `a2a_protocol/` (serveur, client).

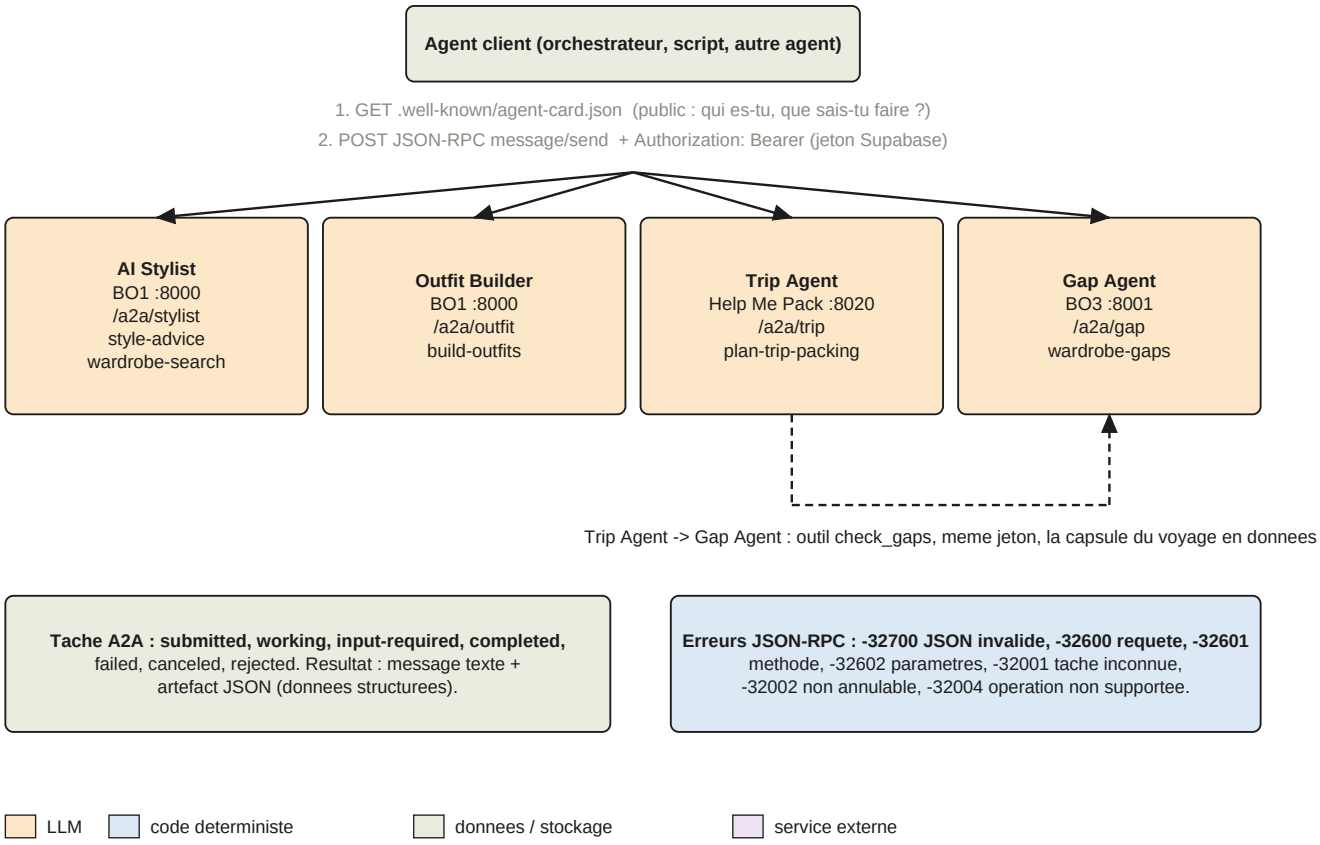


Figure 9 : decouverte par carte, envoi d'une tache, appel d'un agent par un autre.

Agent	Carte d'agent	Point d'entree	Competence (skill)	Donnees acceptees
AI Stylist	/a2a/stylist/.well-known/agent-card.json	POST /a2a/stylist (BO1)	style-advice, wardrobe-search	texte ; city, country, unit
Outfit Builder	/a2a/outfit/.well-known/agent-card.json	POST /a2a/outfit (BO1)	build-outfits	texte ou occasion, season, city, country, avoid
Trip Agent	/a2a/trip/.well-known/agent-card.json	POST /a2a/trip (8020)	plan-trip-packing	texte ou trip {destination, dates, activities, kg}
Gap Agent	/a2a/gap/.well-known/agent-card.json	POST /a2a/gap (BO3 8001)	wardrobe-gaps	texte ou goal ; capsule du voyage

Ce qui est implemente

- Methodes `message/send` (reponse synchrone : une tache terminee), `tasks/get` et `tasks/cancel`.
- **Authentification** : la carte est publique ; chaque tache exige le jeton Supabase (en-tete Authorization) et ne travaille que sur la garde-robe de cet utilisateur. Une tache n'est lisible que par celui qui l'a creee.

- **input-required** : le Trip Agent demande une precision ("quelles dates ?") ; le client renvoie sa reponse avec le meme `contextId` (c'est l'identifiant de la session de voyage).
- Un agent qui plante renvoie une tache **failed** avec un message neutre : aucun detail interne ne sort.
- Non implemente, et declare tel quel dans la carte : streaming (`message/stream`) et notifications push.

Agent vers agent : le Trip Agent demande au Gap Agent

L'outil `check_gaps` du Trip Agent etait un crochet vide. Il appelle maintenant le Gap Agent **par A2A** : il lui envoie la capsule du voyage (destination, activites, jours) et le jeton de l'utilisateur ; le Gap Agent choisit l'objectif le plus proche, classe les pieces manquantes et repond ; le Trip Agent les propose. Si le Gap Agent est arrete, l'outil renvoie une erreur propre et le voyage n'est pas bloque. L'adresse se regle avec `GAP_A2A_URL` (vide pour desactiver).

Decouvrir les agents

`python scripts/a2a_discover.py` lit les quatre cartes ; avec `A2A_TOKEN` et `--ask`, il envoie aussi une tache a chaque agent.

Suite logique

L'orchestrateur devient un **client A2A** : il lit les quatre cartes, choisit l'agent selon les competences annoncees et lui delegue la tache. Les agents sont deja prets pour cela.